

제조 시계열 데이터를 위한 진화 연산 기반의 하이브리드 클러스터링 기법

(Evolutionary Computation-based Hybrid Clustering Technique for Manufacturing Time Series Data)

오상현*, 안창욱**

(Sanghoun Oh, Chang Wook Ahn)

요약

제조 시계열 데이터 클러스터링 기법은 제조 대용량 데이터 기반 군집화를 통한 설비 및 공정 이상 탐지 분류를 위한 중요한 솔루션이지만 기존 정적 데이터 대상 클러스터링 기법을 시계열 데이터에 적용함에 있어 낮은 정확도를 가지는 단점이 있다. 본 논문에서는 진화 연산 기반 시계열 군집 분석 접근 방식을 제시하여 기존 클러스터링 기술에 대한 정합성 향상하고자 한다. 이를 위하여 먼저 제조 공정 결과 이미지 형상을 선형 스캐닝을 활용하여 1차원 시계열 데이터로 변환하고 해당 변환 데이터 대상으로 Pearson 거리 매트릭을 기반으로 계층적 군집 분석 및 분할 군집 분석에 대한 최적 하위클러스터를 도출한다. 해당 최적 하위클러스터 대상 유전 알고리즘을 활용하여 유사도가 최소화되는 최적의 군집 조합을 도출한다. 그리고 실제 제조 과정 이미지 대상으로 기존 클러스터링 기법과 성능 비교를 통하여 제안된 클러스터링 기법의 성능 우수성을 검증한다.

■ 중심어 : 시계열 클러스터링 ; 선형 변환 ; 유전 알고리즘 ; 제조업

Abstract

Although the manufacturing time series data clustering technique is an important grouping solution in the field of detecting and improving manufacturing large data-based equipment and process defects, it has a disadvantage of low accuracy when applying the existing static data target clustering technique to time series data. In this paper, an evolutionary computation-based time series cluster analysis approach is presented to improve the coherence of existing clustering techniques. To this end, first, the image shape resulting from the manufacturing process is converted into one-dimensional time series data using linear scanning, and the optimal sub-clusters for hierarchical cluster analysis and split cluster analysis are derived based on the Pearson distance metric as the target of the transformation data. Finally, by using a genetic algorithm, an optimal cluster combination with minimal similarity is derived for the two cluster analysis results. And the performance superiority of the proposed clustering is verified by comparing the performance with the existing clustering technique for the actual manufacturing process image.

■ keywords : Time Series Clustering ; Linear Scanning ; Genetic Algorithm ; Manufacturing Industry

I. 서론

최근 제조업 분야에서는 가상화, 연결성, 데이터 활용도의 기술에 대한 디지털 전환(digital transformation)을 통하여 스마트 제조 시스템을 활발하게 구축 중에 있다. 특히 정보기술(information technology)과 운영기술(operation technology)의 급속한 발전으로 인한 제조 시스템 자동화 및 IoT 기반 센서 기술, 대용량 데이터 처리를 위한 Cloud Computing 그리고 AI/Big Data 분석 기술을 통하여 지능화 제조 시스템으로 빠

르게 전환되고 있다 [1].

특히 제조 과정에서 수집되는 방대한 양의 데이터 활용하여 기존 제조 과정에서 탐지가 불가능한 Loss들을 발굴하여 생산성 및 품질 관련 개선을 위한 업무가 활발하게 수행되고 있다 [2]. 이를 위한 이상 탐지 방법들은 비교사 학습 방법과 교사 학습 방법으로 분류된다. 먼저 클러스터링은 대표적인 비교사 학습 방법으로 관찰, 데이터 항목 또는 특징 벡터와 같은 패턴을 군집으로 명명된 그룹으로 비지도 분류를 통하여 유사한 데이터들로 그룹화하는 것을 목적으로 한다 [3]. 해당 방법은 다양한 제조 응용 프로그램 이미지 처리, 제조 데이터 마이닝 및 제품

* 정회원, 한국 방송 통신 대학교 컴퓨터과학과 학부생

** 중신회원, 광주과학기술원(GIST) AI대학원 교수

이 논문은 정부(과학기술정보통신부)의 재원으로 한국연구재단의 지원을 받아 수행된 연구임 (No. NRF-2021R1A2C3013687).

접수일자 : 2021년 07월 27일

수정일자 : 1차 2021년 09월 23일, 2차 2021년 09월 24일

게재확정일 : 2021년 09월 27일

교신저자 : 안창욱 e-mail : cwan@gist.ac.kr

마케팅 등 다양한 분야에서 활용 중에 있다. 다음 교사 학습의 대표적인 이상 탐지 방법인 이미지 딥러닝(deep learning)은 제조 분야 결함 영상을 분류하는 기술로 제품의 결함을 실시간으로 분석한 후 분석된 결함 종류에 따라서 생산 시스템에 피드백 함으로써 연속 공정에서 불량 원인을 제거할 수 있다 [4]. 제조업에서 해당 기술 활용 분야는 제조 조건에 따른 불량 패턴을 분석하는 비전 기반 검사 기술이다. 해당 기술을 양산 제조 분야 활용함에 있어 이미지 수집 및 양/불 이미지 라벨링을 위하여 많은 인력과 시간이 소요되며 새로운 이미지 분류 모델 구축을 위한 추가 이미지 수집 및 분류 정합성 개선을 위하여 재학습은 필수적인 요소이다 [1,2]. 이러한 불합리를 효율적으로 개선하기 위하여 이미지 데이터를 시계열 데이터로 변환하여 군집화 하는 방법을 활용한다. 기존 기계 학습 및 데이터 마이닝 알고리즘을 활용할 경우 고차원 데이터, 복잡한 교호 작용 및 다량의 노이즈로 인해 시계열 데이터 활용에 있어 비효율적이다. 특히, 스마트 제조 시스템에서 시계열 분석의 경우 반복되는 패턴들의 인식을 통하여 정상 상태, 이상 및 특징적인 고장 패턴의 정확도 높은 그룹핑하는 것은 패턴의 다양성으로 인하여 난이도가 높은 문제이다. 본 논문에서는 이를 효율적으로 해결하기 위하여 비교사 학습 방법을 활용한 탐색적 데이터 분석 및 요약 기반 다양한 패턴 그룹화가 가능한 유전 연산 기반 하이브리드 시계열 데이터 클러스터링 기법을 제안한다. 해당 기법의 경우 구조적 품질 및 일관성을 가진 클러스터를 생성하기 위한 수행시간과 정확도 측면에서 효율적인 특징을 가지고 있다.

해당 논문 II장에서는 기존 시계열 데이터 클러스터링 기법에 대하여 설명하고 한다. 다음 III 장에서는 제안 유전 연산 기반 시계열 클러스터링 알고리즘에 대하여 자세하게 설명하고 IV 장에서는 실제 제조 데이터 대상으로 제안 알고리즘의 성능을 비교 분석한다. 그리고 결론을 도출하고 향후 전망을 논의하면서 본 논문을 마무리한다.

II. 관련 연구

일반적으로 시계열 데이터 클러스터링은 계층적, 분할, 그리고 모델 기반 클러스터링의 총 3가지 기법으로 분류된다. 먼저 계층적 클러스터링은 유사한 객체의 중첩된 계층에 대한 쌍별 거리 행렬 기반으로 구성되며 결과에 대한 뛰어난 시각화 능력에 장점이 있다. 그리고 대부분 클러스터링 기법의 경우 클러스터 수를 초기 매개 변수로 정의해야 하지만 계층적 클러스터링에서는 사전 정의가 불필요하다는 장점이 있다 [5]. 반면에 대용량 시계열 데이터 대상으로 활용할 경우 계산 복잡성으로 인하여 소규모 데이터 세트로 제한하여 활용해야 하는 단점이 있다. 다음 분할 클러스터링은 계층적 클러스터링 대비 빠른 수행 속도로 인하여 시계열 클러스터링 활용에 적합하고 fuzzy 이론

방식과 결합하여 사용가능하다. 그러나 군집 개수 사전 정의로 인하여 클러스터 정합성 확보가 어렵고 대규모 데이터 대상 수행 시간이 느려지는 단점이 있다 [5,8]. 마지막 모델 기반 클러스터링은 각 클러스터에 대한 모델을 가정하고 해당 모델에 가장 적합한 데이터를 결정한다. 즉, 주어진 데이터에서 생성된 모델을 클러스터로 정의한다.

기존 시계열 데이터 클러스터링 알고리즘 성능 향상을 위한 다양한 맞춤형 방법들이 제안되었다. 처음으로 Lai [11]은 전체 시계열과 시계열의 하위 시퀀스가 각각 첫 번째 및 두 번째 수준에서 고려되는 2단계 클러스터링 방법을 제안하였다. 주어진 데이터 차원 축소를 위하여 Symbolic Aggregate ApproXimation 변환을 사용하고 데이터 그룹화 클러스터링 알고리즘으로 Cluster Affinity Search Technique를 사용하였다. 시계열 데이터 유사도 측정을 위하여 데이터 길이가 상이한 경우 dynamic time warping을 사용하고 동일한 길이의 데이터 경우에는 유클리드 거리를 사용한다. 다음으로 Siddiqi [12]는 모양 기반 시계열 클러스터링을 위한 새로운 다단계 접근 방식을 제안하였다. 처음으로 생성된 하나의 가장 가까운 이웃 네트워크에서 시계열 데이터를 선택하고 삼각형 거리 측정을 통하여 시계열 네트워크 생성한다. 다음으로 선택한 시계열 데이터 대상으로 계층적 클러스터링을 수행하여 데이터 크기를 대략 10%로 축소 가능하지만 가장 가까운 이웃 네트워크 생성함에 있어 $O(n^2)$ 로 다소 높은 시간 복잡성을 가진다. 그러나 네트워크 생성 자체는 비용이 많이 들고 대규모 데이터 세트에 적용할 수 없으며, 삼각형이 거리 측정으로 사용될 때 k-means 방법을 통해 프로토타입을 생성하는 문제에 대한 해결책은 명확하지 않다는 단점이 있다.

본 논문에서는 새로운 클러스터링 시계열 분석을 통하여 기존 클러스터링 기술에 대한 견고성을 보장하는 새로운 시계열 데이터 군집 분석 알고리즘을 제안한다. 먼저 선형 스캐닝 기법을 활용하여 제조 과정 2차원 이미지를 1차원 시계열 데이터 변환한다. 다음으로 변환되어진 시계열 데이터 대상으로 Pearson 상관계수 거리 측정 기법 기반 총 평균 연결이 있는 계층적 클러스터링 방식과 분할 클러스터링 방식을 사용하여 각 방식에 대한 최적 하위 그룹을 형성한다. 마지막으로 대표적인 최적화 기법인 유전 알고리즘(genetic algorithm)을 활용하여 유사도가 최소가 되는 각 클러스터링 최적 그룹들로부터 최적의 조합을 도출한다. 특히 제안 시계열 클러스터링 알고리즘의 경우 모양의 유사성을 기반으로 시계열 데이터를 클러스터링의 정확도 향상을 통하여 대용량 이미지로부터 최적의 그룹 도출이 가능하여 제조업 유사 이미지 라벨링 및 이상 탐지를 위한 대표 이미지 그룹 도출에 활용이 가능하다.

III. 유전 연산 기반 하이브리드 시계열 클러스터링

본 장에서는 유전 연산 기반 시계열 데이터 클러스터링을 위한 하이브리드 접근 방식에 대하여 자세하게 설명한다. 제안 기법에서는 다양하고 불규칙한 모양의 객체를 포함하는 데이터셋으로 부터 특정 객체 유형의 최적 군집의 클러스터를 도출하는 것을 목적으로 한다.




그림 1. 제안 Hybrid 클러스터링 알고리즘 동작 과정




그림 2. 2D 이미지 데이터 1D 시계열 데이터 선형 변환 예시

그림 1에서는 제안 시계열 클러스터링 알고리즘에 대한 전체 동작 과정을 보여준다. 제조 과정에서 수집되는 2차원 이미지로부터 1차원 시계열 형태로 데이터 변환, Pearson 거리 측정 기반 계층 및 분할 클러스터링 알고리즘 수행을 통한 최적화 하위 그룹 도출 과정, 유전 연산 기반 최적 클러스터링 조합 도출, 성능 평가의 총 4가지 단계로 구성된다. 처음 단계에서는 선형 스케닝을 활용하여 주어진 모든 2차원 이미지에서 무손실 변환 재구성을 통하여 1차원 시계열 데이터로 변환을 수행한다. 그림 2에서는 실제 제조 과정에서 발생하는 유사 이미지 대상으로 선형 스케닝을 활용하여 시계열 데이터로 변환하는 구체적인

예시를 보여준다. 총 4×4 행렬 이미지 데이터로 각 요소는 불량 정도를 나타내는 수치이며 순차적인 요소 번호에 따라 해당 수치 매칭하여 시계열 데이터를 생성한다.

다음 단계에서는 변환된 시계열 데이터로부터 유사 이미지에 대한 그룹화를 위하여 주어진 군집 개수에 대한 Pearson 상관 계수 거리 측정 기반으로 계층적 클러스터링 및 분할 클러스터링을 결과를 도출하여 대표적인 클러스터링 평가 지표인 Silhouette width를 활용하여 최적의 군집을 도출한다 [10]. 먼저 본 논문에서 사용한 클러스터링 유사도 측정은 Pearson 상

$$\sigma_{X,Z} = \frac{\sum_{c=1}^n (X_c - \bar{X})(Z_c - \bar{Z})}{\sqrt{\sum_{c=1}^n (X_c - \bar{X})^2} \sqrt{\sum_{c=1}^n (Z_c - \bar{Z})^2}} \quad (1)$$

관 계수 거리 다음과 같이 정의된다.

여기서 Pearson 상관 계수에서 상관관계는 두 개의 시계열 데이터 변수 X, Z 사이에서 측정된다. 그리고 본 논문에서 사용하는 Pearson 거리는 다음과 같이 정의한다 [7].

$$dist_{pe}(X, Z) = 1 - \sigma_{X,Z} \quad (2)$$

여기서 $\sigma_{X,Z}$ 는 두 개의 임의의 시계열 데이터 X, Z 간의 상관 계수를 나타낸다. $dist_{pe}$ 값은 0과 2 사이의 수로 표현되며 해당 값이 0인 경우 두 계열이 모양이 완벽하게 동일한 반면에 2의 값을 가진 경우 두 계열의 모양이 완전하게 다르다는 것을

의미한다. 제안 기법에서 사용한 Pearson 상관계수 기반 거리 측정 방법은 Dynamic Time Wrapping (DTW) 알고리즘 대비 수행속도가 빠르고 데이터 정규화(normalization)를 통한 거리 계산으로 인하여 시계열 대상 (비)유사성이 설명이 가능한 장점은 있지만 진폭의 차이는 설명이 불가능하다는 단점이 있다. 본 논문에서 제안 기법은 정확한 진폭의 차이보다는 유사성 비교를 통한 유사 시계열 (이미지) 유형에 대한 군집화가 중요하여 Pearson 상관계수 기반 거리 계산 방법을 활용한다. 시계열 데이터 대상으로 주어진 군집 개수에 대한 계층적 및 분할 군집 분석을 통하여 최적의 군집 개수의 하위 클러스터로 분할된다. 먼저 분할 클러스터링의 경우 하위 클러스터는 시계열 선호도 계수를 기반으로 생성된 거리 측정 결과로 표시된다. 여기서 사전 정의된 k개의 서로 다른 클러스터로 나누는 것으로 동일 군집 내 관측치와 사이 거리를 최소화 및 군집 간 사이의 거리를 최대화한다. 다음 계층적 클러스터링은 클러스터의 계층 구조 구축을 통하여 최적의 클러스터 도출한다. 본 논문에서는 활용된 계층적 클러스터링 기법은 서로 다른 클러스터를 반복적으로 병합하여 마지막 클러스터가 있을 때까지 수행하는 방식을 사용한다. 각 클러스터링 알고리즘에서 최적 클러스터링 도출을 위하여 Silhouette width를 결과 평가 지표로 사용한다 [10]. 해당 지표는 군집내의 요소가 얼마나 가까운지를 나타내는 척도 및 군집 간 얼마나 구별되는지를 측정하는 척도를 사용하여 최적의 군집 수를 도출한다. 해당 지수는 다른 군집과의 거리는 떨어져 있고 동일 군집 내 데이터는 서로 가깝게 잘 뭉쳐 있는지를 평가한다.

$$Silhouette\ Width = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \quad (3)$$

여기에서 $a(i)$ 는 i 번째 개체와 같은 군집에 속한 요소들 간 거리들의 평균이며, $b(i)$ 는 i 번째 개체와 다른 군집에 속한 요소들 간 거리들의 평균입니다. 여기서 $b(i)$ 는 i 번째 개체가 속한 군집과 가장 가까운 이웃 군집을 택해서 계산한 값이다. Silhouette width는 -1에서 1까지 범위의 값을 가지며 큰 값을 가질수록 군집화가 잘 되었다고 판단하고, 반대로 작은 값을 가진 것은 잘 군집되지 않은 것을 의미한다. 제안 기법에서 Silhouette width를 활용하여 분할 및 계층적 클러스터링에 대한 최적의 군집수를 도출한다. 마지막으로 각 클러스터링을 통하여 분할된 최적 클러스터들 대상으로 대표적인 진화 기법인 유전자 알고리즘을 활용하여 최적의 군집화 조합을 도출한다. 이를 통하여 주어진 데이터 대상으로 우수한 성능을 가지는 클러스터링 알고리즘을 통하여 기존 클러스터링 알고리즘의 정합성 한계를 극복 가능하다. 여기서 사용되는 유전자 알고리즘은 자연 선택의 원리에서 영감을 받은 확률적 검색 알고리즘으로 이를 통하여 높은 복잡성을 가지는 실세계 문제해결이 가능하다. 이를 위

하여 생성되는 후보 해는 주어진 문제 해결을 위하여 설계되는 적합도 함수 값들이 할당된다. 그림 1에서 유전 알고리즘의 전체 동작 과정을 묘사한다. 최적 클러스터링 조합을 도출하기 위하여 유전 알고리즘 적용함에 있어 해를 정의하는 것은 매우 중요하다. 제안 기법에서 해를 표현하는 유전자의 길이를 계층 및 분할 군집 분석에서 도출되는 최적 클러스터 개수의 합으로 정의하고 각각의 유전자에 클러스터 번호 부여하고 이진 문자열을 통하여 선택 여부로 부호화한다. 그림 3에서는 본 논문에서 사용하는 유전자 표현 방법을 묘사한다. 여기서 계층 군집 분석에서 최적의 4가지 하위 군집을 도출하였으며, 분할 군집분석에서 총 3가지 최적 클러스터가 도출되어 총 길이가 7인 유전자로 표현된다. 그리고 1번, 3번, 5번, 그리고 6번 클러스터를 조합을 하나의 후보 해로 정의한다.

C_1	C_2	C_3	C_4	C_5	C_6	C_7
1	0	1	0	1	1	0

그림 3. 제안 하이브리드 유전자 표현 방법




그림 4. 제안 하이브리드 교배 방법

C_1	C_2	C_3	C_4	C_5	C_6	C_7
1	0	1	0	1	1	0

Mutation Point

그림 5. 제안 하이브리드 돌연변이 방법

다음 과정인 적합도 함수 평가는 주어진 문제 해결을 위하여 후보 해가 정확하게 평가하는 것을 목적으로 한다. 제안 하이브리드 클러스터링 기법에서 적합도 함수는 다음과 같이 정의한다.

$$TSC_{dist} = \frac{\sum_{i=1}^n \max_{j \in k} \{dist_{pe}(pop_i, C_j)\}}{n} \quad (4)$$

여기서 TSC_{dist} 는 부호화 유전자 대상 클러스터 대상 거리에 대한 평균 거리를 도출한다. 여기서 n 은 유전자 알고리즘에서 해의 크기, k 는 유전자 부호화를 위한 총 클러스터 개수를 의미한다. 그리고 pop_i 는 i 번째 후보 해를 C_j 는 j 번째 군집을 의미한다.

해의 다양성 및 우수성을 확보를 위한 총 3가지 유전 연산자

에 대하여 설명한다 [6]. 먼저 선택 연산자는 가장 적합한 개체를 다음 세대로 전이하는 적자생존(survival of fitness)을 기반으로 수행된다. 해당 연산의 목적은 높은 적합도 함수 값을 가진 개체를 다음 세대로 전이하는 것이다. 다음 연산자 교배의 경우 두 부모의 조합을 통하여 새로운 개체를 생산을 통한 해의 다양성을 위한 유전 연산자이다. 본 논문에서는 단일 포인트 교배 기법을 사용하여 두 부모 개체에서 무작위로 선택되고 해당 포인트의 한쪽에 있는 유전 물질이 다른 부모와 교환되어 새로운 두 개의 자손 개체를 생성한다. 그림 4에서는 기존 해 $(C_1, C_3, C_5, C_6, C_7)$ (C_2, C_3, C_6, C_7) 에서 $(C_2, C_3, C_5, C_6, C_7)$ (C_1, C_3, C_6, C_7) 의 새로운 해를 생성하는 교배 동작 과정을 보여준다. 이를 통하여 다음 세대에서 해의 다양성을 가질 수 있다. 마지막 연산자인 돌연변이의 경우 단일 부모 개체를 통하여 자손이 생성되도록 변이하여 해가 국소적 수렴되는 것을 방지하여 최적화의 해로 수렴되는 것을 목적으로 한다. 해당 연산의 경우 작은 변화의 결과로 간주되기 때문에 돌연변이 확률을 낮게 설정하여 부모의 유전물질의 대부분이 자손에 존재하여 높은 유사성을 유지한다. 그림 5에서는 본 연구에서 사용된 돌연변이 기법을 묘사한다. 현재 해 (C_1, C_3, C_5, C_6) 에서 돌연변이 연산을 통하여 3번째 클러스터 선택 해제하여 새로운 해 (C_1, C_5, C_6) 를 생성하여 다음 세대로 전이한다.

본 논문에서는 이러한 유전 알고리즘 활용하여 시계열 데이터 클러스터링 결과 조합하여 최적의 클러스터 조합을 도출한다. 이를 통하여 기존 대비 정합성 향상이 가능하다. 다음 절에서는 실제 제조 데이터 기반으로 제안 알고리즘의 성능을 검증 결과를 설명한다.

IV. 실험 결과

실제 제조업에서 수집되는 데이터 셋을 사용하여 제안 기법의 성능을 평가한다. 이를 위하여 R에서 제공하는 오픈라이브러리 활용하여 Pearson 상관계수 매트릭스 기반 시각적 유사성 계산 및 선형 변환 기반 시계열 데이터 변환을 수행한다 [10]. 그리고 분할 / 계층적 군집분석 및 최적 클러스터링 도출을 위한 활용한 유전 알고리즘 또한 R 라이브러리 활용하여 구현하였다. 성능 평가를 위한 컴퓨터 사양은 MacBook Pro 3.1GHz Dual-Core Intel Core i5 16GB 사용한다.

제안 알고리즘의 경우 Pearson 상관 계수 기반의 거리 측정 기반 분할 및 계층적 군집 분석 기법에서 Silhouette width 유사성 검증을 통하여 최적의 클러스터를 도출한다. 다음으로 도출된 최적 하위 클러스터 대상으로 진화 기법 적용을 통하여 최적 클러스터 조합이 되도록 하위 클러스터 병합한다. 제안 기법은 기존 시계열 데이터 클러스터링 기법(분할 군집 분석 PC_{opt}

그리고 계층적 군집 분석 HC_{opt})들의 Pearson 상관계수 거리 측정 결과를 통하여 성능을 검증한다. 그리고 본 논문에서 제안 시계열 데이터 클러스터링에 사용한 유전 알고리즘에서 알고리즘 해의 크기는 분할 군집 분석 및 계층적 군집 분석의 최적 클러스터 개수의 합에 50배로, $PopSize = \{n(HC_{opt}) + n(PC_{opt})\} \times 50$ 로 정의한다. 그리고 알고리즘 해의 수렴을 위한 반복 횟수는 해의 크기에 제곱근에서 1.5배로 $N_{iter} = 1.5 \times \sqrt{PopSize}$ 정의한다. 다음 세대 우수한 개체 확보를 위하여 토너먼트 선택을 사용한다. 그리고 해의 다양성 확보를 위한 교배 연산 및 돌연변이 연산은 각각 0.8 및 0.1의 확률로 적용된다.

모든 주어진 시계열 데이터는 z-score $z = (x - \mu) / \sigma$ 활용하여 정규화 수행한다. 기존 계층적 군집 클러스터링에서는 한 군집의 각 점과 다른 군집의 모든 점 사이의 평균 거리로 군집 간의 유사도를 Pearson 상관 계수 기반으로 측정한다. 여기서 군집 개수를 2에서 5까지의 Silhouette width 결과 비교를 통하여 최대값을 가지는 클러스터 개수를 최적 군집수로 정의한다. 다음 분할 시계열 데이터 클러스터링 또한 Pearson 상관 계수 기반으로 주어진 군집 계수 단위 Silhouette width 결과 비교를 통하여 최적의 하위 클러스터 개수를 도출한다. 기존 두 가지 클러스터링에서 도출된 최적 하위 군집 대표 유형을 후보 군으로 유전 알고리즘 활용하여 Pearson 상관 계수 기반 거리 유사도 측정 적합도 함수가 최소화 되는 최적 군집 조합을 도출한다. 이를 통하여 시계열 데이터 유형 단위 적합한 대표 패턴을 조합 도출이 가능하다. 기존 시계열 데이터 클러스터링 및 제안 기법의 성능 비교 검증을 위하여 실제 chip 단위 제조 과정에서 수집된 이미지 데이터 셋을 사용한다. 여기서 활용한 데이터에 대한 구체적 설명은 제조 보안상의 문제로 제외한다. 전체 데이터는 총 6164장으로 구성되어 있으며, 25% 데이터 셋을 무작위 추출 100회 반복하여 제안 기법과 기존 클러스터링 기법과의 성능을 비교 검증한다.

그림 6~8에서는 전체 이미지 중 25%인 1374장 대표 이미지 대상으로 계층적 군집 분석, 분할 군집분석 그리고 제안 군집분석 수행 결과 예시를 보여준다. 먼저 계층적 군집 분석에서는 총 4가지 최적 클러스터를 도출되었다. 첫 대표 이미지에 군집(687장)에 대한 95% 신뢰구간 (0.0964, 0.1014), 두 번째 대표 이미지(221장)에 대한 95% 신뢰구간 (0.0593, 0.0690), 세 번째 대표 이미지(353장)에 대한 95% 신뢰구간 (0.1007, 0.1152), 그리고 마지막 대표 이미지(113장)에 대한 95% 신뢰구간 (0.1878, 0.2228)의 결과를 나타냈다. 전체 평균 및 표준 편차 0.1044 ± 0.0623 그리고 95% 신뢰구간 (0.1011, 0.1077)의 결과를 도출하였다. 다음 분할 군집분석에서는 총 3가지 최적 클러스터를 도출되었다. 첫 대표 이미지에 군집(687장)에 대한 95% 신뢰구간 (0.0792, 0.0847), 두 번째 대표 이미지(466장)에 대한

95% 신뢰구간 (0.1897, 0.2197), 마지막 대표 이미지(221장)에 대한 95% 신뢰구간 (0.0518, 0.0613)의 결과를 나타냈었다. 전체 평균 및 표준 편차 0.1195 ± 0.1180 그리고 95% 신뢰구간 (0.1132, 0.1257)의 결과를 도출하였다. 마지막 제안 하이브리드 시계열 클러스터링 분석에서는 총 4가지 최적 클러스터를 도출하였다. 첫 대표 이미지에 군집(353장)에 대한 95% 신뢰구간 (0.1007, 0.1152), 두 번째 대표 이미지(113장)에 대한 95% 신뢰구간 (0.1878, 0.2228), 세 번째 대표 이미지(687장)에 대한 95% 신뢰구간 (0.0792, 0.0847), 그리고 마지막 대표 이미지 (221장)에 대한 95% 신뢰구간 (0.0518, 0.0613)의 결과를 나타냈다. 전체 평균 및 표준 편차 0.0947 ± 0.0650 그리고 95% 신뢰구간 (0.0912, 0.0981)의 결과를 도출하였다. 제안 알고리즘의 Pearson 상관계수 기반 유사도 결과 최소 평균 및 표준 편차가 결과를 그리고 95% 신뢰 구간에서도 유사도가 제일 낮은 구간을 도출하였다.

마지막으로 총 6164장으로 이미지 데이터 셋의 25% 데이터 중복 없이 무작위 추출하는 과정을 총 100번 반복을 통하여 도출된 Pearson 상관 계수 기반의 유사도를 결과 비교를 통하여 제안 클러스터링 기법의 성능을 비교 검증하였다. 먼저 제안 기법의 유사도 평균 유사도 값은 0.1343로 분할 군집 분석 0.1525 및 계층 군집 분석 유사도 0.1762 보다 작았다. 그리고 최소값, 최대값, 사분위수의 대부분 유사도 통계값을 통하여 제안 기법의 성능 우수성을 확인하였다. 특히 95% 신뢰 구간 비교를 통하여 제안 클러스터링 알고리즘의 신뢰 구간이 (0.1298, 0.1387)로 기존 분할 및 계층적 시계열 군집 분석 신뢰 구간 (0.1433, 0.1617) 및 (0.1726, 0.1798)보다 우수함을 검증하였다. 이를 통하여 실제 제조 과정 활용함을 통하여 실제 양산 이미지 그룹핑 및 불량 검출을 위한 대표 이미지 그룹 도출이 용이하여 다양한 제조 분야에 활용이 가능하다.




그림 6. 계층적 시계열 클러스터링 수행 결과 예시




그림 7. 분할 시계열 클러스터링 수행 결과 예시




그림 8. 제안 Hybrid 시계열 클러스터링 수행 결과 예시

표 1. 제안 군집 분석 알고리즘 성능 검증 결과

	$Hybrid_{opt}$	PC_{opt}	HC_{opt}
Mean	0.13426	0.17620	0.15253
Std	0.02277	0.01828	0.04702
Min	0.09149	0.12701	0.09215
Q1	0.11818	0.16462	0.11525
Q2	0.13010	0.18605	0.13954
Q3	0.14721	0.18864	0.17166
Max	0.19205	0.19507	0.33924
95% CI	(0.1298, 0.1387)	(0.1726, 0.1798)	(0.1433, 0.1617)

V. 결 론

본 논문에서는 실제 제조 과정에서 수집되는 다양한 이미지 대상으로 모양의 객체를 클러스터링하는 유전 알고리즘 활용한 병합 군집분석 방법을 제안하였다. 먼저 선형 스캐닝을 통한 수집된 2D 이미지 1D 시계열 데이터 변환하여 해당 시계열 데이터 대상으로 Pearson 상관관계 기반 계층적 군집 분석과 분할 군집 분석 알고리즘을 사용하여 최적 하위 클러스터 도출하였다. 다음으로 진화 기법을 활용하여 Pearson 상관관계 유사도가 최소화 되는 하위 클러스터에 대한 최적 조합을 도출하였다. 실제 제조업 이미지 대상으로 기존 시계열 클러스터링 기법과 제안 Hybrid 시계열 클러스터링 기법과의 비교를 통하여 성능 우수성을 검증하였다. 제안 기법의 경우 특히 제조 과정에서 대용량으로 수집되는 다양한 이미지 대상으로 정상 상태, 이상 및 특징적인 고장 패턴의 정확도 높은 군집화가 가능하지만 제안 기법의 경우 Pearson 거리 기반 계층적 군집 분석 및 분할 군집 분석에서 도출된 하위 클러스터 대상으로 병합을 수행하기 때문에 해당 군집 분석 기법에 성능이 좌우되므로, 이 부분을 효율적으로 해결하기 위하여 추후 다양한 군집 분석 알고리즘 기반 최적 병합알고리즘 연구가 필요하다.

REFERENCES

- [1] 노규성, 박상휘, “제조실행시스템의 빅데이터 적용 방안에 대한 탐색적 연구,” *Journal of Digital Convergence*, 제12권, 제1호, 305-311쪽, 2014년 12월
- [2] 광기호, 이하목, “제조업 빅데이터 활용 동향 분석과 시사점,” *주간기술동향*, 2016년 9월
- [3] 최철웅, 김경백, “폐암환자 생존분석에 대한 tnm 병기 군집 분석 평가,” *스마트미디어저널*, 제9권, 제4호, 126-133쪽, 2020년 12월
- [4] 이동수, A.K.M. Ashiquzzaman, 김영광, 신혜주, 김진술, “K-평균 군집화 알고리즘 및 딥러닝 기반 군중 집계를 이용한 전염병 확진자 접촉 가능성 여부 판단 모니터링 시스템 제안,” *스마트미디어저널*, 제9권, 제3호, 122-129쪽, 2020년 9월
- [5] S. Aghabozorgi, A.S. Shirkhorshidi, and T.Y. Wah, “Time-series clustering - A decade review,” *Information Systems*, vol. 53, pp. 16-38, Oct., 2015.
- [6] M. Chis, S. Banerjee, and A.E. Hassanien, “Clustering Time Series Data: An Evolutionary Approach,” *Foundations of Computational Intelligence* vol. 6, pp. 193-207, 2009.
- [7] A. Mondal, N. Dey, S. Fong, and A.S. Ashour, “A hybrid shape-based image clustering using time-series analysis,” *Multimedia Tools and*

- Applications*, vol. 80, pp. 3793-3808, Sep., 2020.
- [8] B. Andreopoulos, A. An, X. Wang, and M. Schroeder, “A roadmap of clustering algorithms: Finding a match for a biomedical application,” *Briefings in Bioinformatics*, vol. 10, no. 3, pp. 297-314, May, 2009.
- [9] C.Y. Hsu, and W.C. Liu, “Multiple time-series convolutional neural network for fault detection and diagnosis and empirical study in semiconductor manufacturing,” *Journal of Intelligent Manufacurting*, vol. 32, pp. 823- 836, May, 2020..
- [10] S.E. Alexis, “Comparing Time-Series Clusteinrg Algorithms in R Using the dtwclust Package,” *The R Journal*, vol. 11, no. 1, Jun., 2019.
- [11] M. Leng, X. Lai, and G. Tan, “Time series representation for anomaly detection,” *2nd IEEE International Conference on Computer and Information*, pp. 628-632, Beijing, China, Aug., 2009.
- [12] M. Munir, S.A. Siddiqui, A. Dengel, and S.Ahmed, “A deep learning approach for unsupervised anomaly detection in time series,” *IEEE Access*, vol. 7, pp. 1991-2005, Dec., 2018.

 저 자 소 개



오상헌 (정회원)

2011년 광주과학기술원 정보통신
공학과 박사 졸업.

2011년 ~ 2018년 삼성전자 생산
기술연구소 책임연구원.

2020년 ~ 현재 한국 방송통신대
학교 컴퓨터과학과

2018년 ~ 현재 SK Hynix P&T Data Science 수
석 연구원.

<주관심분야: 메타-진화 알고리즘, 기계 학습 기반
제조 빅데이터 분석>



안창욱 (증신회원)

2005년 광주과학기술원 정보통신
공학과 박사 졸업.

2005년 ~ 2007년 삼성종합기술원
전문연구원.

2008년 ~ 2017년 성균관대학교
컴퓨터공학과 부교수.

2017년 ~ 현재 광주과학기술원 전기전자컴퓨터
공학과/AI대학원 교수.

<주관심분야: 메타-진화 알고리즘, 쿼텀 기계 학
습, 진화 강화 학습, AI 음악>